

Inteligência Computacional

*Licenciatura em Engenharia Informática, Engenharia Informática – Pós Laboral e
Engenharia Informática – Curso Europeu*

3º Ano – 1º semestre

2021/2022

PROJECTO – FASE I

1. Âmbito e Objetivo

O Projeto, constituído por Fase I - Análise, Fase II - Seminário e Fase III e Desenvolvimento, combina a realização de um trabalho de investigação com o desenho e implementação de uma aplicação para classificação de diversos tipos de padrões. As diversas fases envolvem a escolha de um problema (caso real), definição de um modelo para aprendizagem automática (Fase I), estudo de um algoritmo para otimização da arquitetura (seminário), implementação e validação da solução final (Fase III).

Esta primeira fase do trabalho envolve:

- Escolha de um problema (dataset);
- Análise do problema e recolha de dados;
- Escolha do modelo (definição da arquitetura de uma rede neuronal: número de camadas, neurónios por camada, funções de ativação, algoritmo de treino, coeficientes de aprendizagem, etc.);
- Treino do modelo;
- Avaliação do desempenho.

As fases de seleção de características, otimização do modelo (escolha de hiper-parâmetros) e produção (implementação de um protótipo) serão objeto de estudo na Fase II e III do Projeto.

Esta primeira fase poderá ser realizada em Matlab ou Python.

2. Caso de Estudo

A metodologia deverá ser aplicada a um problema de classificação, com os seguintes requisitos mínimos:

- **Um mínimo de 3 classes;**
- Um valor mínimo de 1 000 amostras para treino;
- Um mínimo de 10 *features* (ou atributos);

Como possíveis escolhas e respeitando os requisitos definidos apresentam-se os seguintes problemas:

- *Australian Sign Language signs Data Set*
Amostra de gestos Auslan (linguagem gestual australiana). A base de dados contém exemplos de 95 gestos, recolhidos de 5 pessoas.
 - Número de exemplos: 6 650
 - Número de atributos: 15
 - Número de classes: 95<https://archive.ics.uci.edu/ml/datasets/Australian+Sign+Language+signs>
- *Coverttype Data Set*
Prever o tipo de cobertura florestal a partir de variáveis cartográficas.
 - Número de exemplos: 581 012
 - Número de atributos: 54
 - Número de classes: 7<https://archive.ics.uci.edu/ml/datasets/Coverttype>
- *notMinist Data Set*
Este dataset é uma alternativa ao Mnist para reconhecimento das letras do alfabeto, sendo mais complexo.
 - Número de exemplos: 450 000
 - Número de atributos: Imagem 28x28 (754)
 - Número de classes: considerar apenas 10 classes (escolhidas pelo grupo de alunos).<https://www.kaggle.com/lubaroli/notmnist>
- *Flowers dataset*
Este conjunto de dados contém imagens de cinco espécies de flores. Para cada classe existem cerca de 800 fotos de 320x240 pixels.
 - Número de exemplos: 4242
 - Número de atributos: Imagem (76 800)
 - Número de classes: 5.<https://www.kaggle.com/alxmamaev/flowers-recognition>
- *Food Images (Food-101)*
Imagens de alimentos rotulados em 101 categorias.
 - Número de exemplos: 10 099 para treino + 1 000 para teste
 - Número de atributos: Imagem 32 x 32 x 3 (=3 072)
 - Número de classes: 101.<https://www.kaggle.com/kmader/food41>
- *O CIFAR-100*
Consiste em 60000 imagens de dimensão 32x32 de 100 classes, com 600 imagens por classe. Por sua vez as 100 classes são agrupadas em 20 superclasses. Cada imagem tem um “label” indicando a classe e a superclasse à qual pertence. Existem 50000 imagens de treino e 10000 imagens de teste.

- Número de exemplos: 60000 (50 000 para treino + 10 000 para teste)
- Número de atributos: Imagem 32x32 (=1 024)
- Número de classes: 100/20 superclasses. Selecionar 10 superclasses para implementar o classificador (escolhidas pelo grupo de alunos).

<https://www.cs.toronto.edu/~kriz/cifar.html>

Para o problema selecionado, deve descrever o objetivo do classificador e responder às questões: Quais as características das amostras? Como são representadas? Quantos exemplos existem por classe? Qual o modelo de classificador mais adequado? Etc.

3. Desenvolvimento do Modelo – Classificador

Deverá ser desenvolvido um modelo baseado numa rede neuronal capaz de resolver a tarefa de classificação.

O desempenho do modelo (classificador) deve ser avaliado para o conjunto de teste, apresentando a matriz de confusão e resultado para as principais métricas: “accuracy”, sensibilidade, especificidade, f-measure e AUC.

Caso o conjunto de teste não seja explicitamente definido na base de dados, devem ser escolhidos aleatoriamente 20% dos dados. Devido à natureza aleatória desta escolha, as simulações devem ser repetidas pelo menos 10 vezes.

Devem ser testadas várias configurações de redes neuronais. Pode ser considerada uma rede MLP, CNN ou outras.

Caso o modelo seja implementado em Python deve recorrer-se às bibliotecas:

- <https://scikit-learn.org/stable/>
- <https://www.tensorflow.org/>
- <https://keras.io/>

Deve-se analisar e avaliar diferentes soluções e estabelecer uma análise comparativa e crítica.

4. Relatório do Projeto

O relatório deve seguir a seguinte estrutura, com o máximo de 6 páginas:

- Cap. 1: Descrição do caso de estudo e objetivos do problema;
- Cap. 2: Descrição da Implementação dos algoritmos;
- Cap. 3: Análise de Resultados;
- Cap. 4: Conclusões;
- Referências.

5. Avaliação

O trabalho é realizado em grupos de 2 alunos.

A documentação final a submeter no Moodle consiste em:

- Relatório;
- Código;
- Slides de apresentação.

Submissão de tema – 05 novembro 2021

Submissão de relatório final – 19 novembro 2021

Apresentação e defesa: semana entre 22 e 26 de novembro de 2021

Cotação: 2 valores