Instituto Superior de Engenharia de Coimbra
Engenharia Informática
Inteligência Computacional

notMinist Data Set

Inteligência Computacional

2021/2022

Projeto - Fase I

Diogo Dias Lopes– a2018019746
Leonardo Marques - a2019123778

Índice

Cap. 1: Descrição do caso de estudo e objetivos do problema

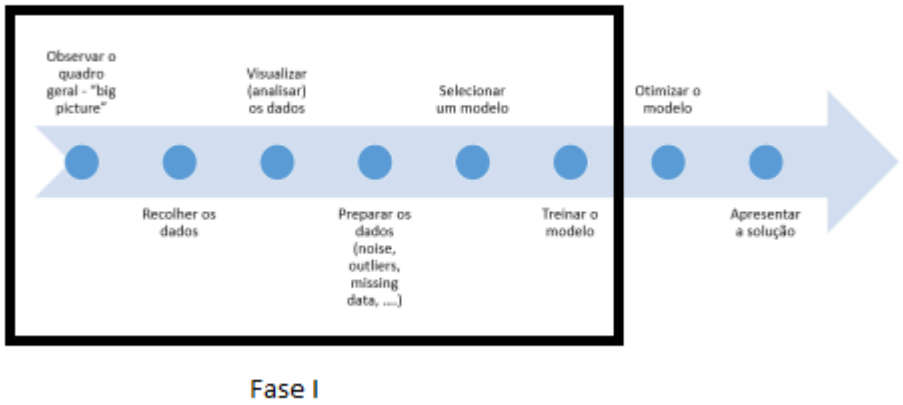

Fig. 1 – Etapas de um processo de Machine learning

Quanto à observação do quadro geral “big picture”.

O caso de estudo em questão tem por um base o notMnist Data set, um dataset que é uma alternativa ao dataset tradicional Mnist para reconhecimento das letras do alfabeto, sendo mais complexo.

Este mesmo dataset foi desenvolvido por Yaroslav Bulatov.

Sendo que para o trabalho usamos a sua versão mais curta que contém as suas especificações:

o Número de exemplos: 18724

o Número de atributos: Imagem 28x28 (754)

o Número de classes: 10 classes (letras A-J)

Este dataset é nos disponibilizado através de um diretório raiz chamado notMNIST_small que contem várias pastas com o nome de cada letra sendo que em cada uma destas pastas se encontram os exemplos de cada tipo de letra correspondente.

Cap. 2: Descrição da Implementação dos algoritmos

Fizemos a implementação deste algoritmo em matlab.

Para isso tivemos que usar uma função em python que convertia o dataset inicialmente disponibilizado para um ficheiro .mat, sendo assim possível a sua utilização em matlab. Esta função python encontra-se no ficheiro de submissão.

A arquitetura da rede neuronal utilizada foi **MLP**

MLP-Redes de múltipla camada

As redes de múltipla camada resolvem problemas não linearmente separáveis. Este algoritmo permite modificar os pesos de qualquer rede de modo que, sendo-lhe apresentado um padrão, ele tenha como output o padrão pretendido.

DEFINIÇÃO DAS ENTRADAS E SAÍDAS DA REDE

Os dados para o treino e de teste usámos o dataset notMNIST_small. Cada imagem tem uma única letra de tamanho 28x28, para o treino temos dois conjuntos em que o primeiro é uma matriz 784x18724 com todas as imagens (em grayscale) e outra matriz 10x18724 que corresponde às 10 classes, onde cada classe é representada por um valor de 0 a 9 que corresponde uma letra de A-Z respetivamente.

Para a saída temos valores de 1 a 10 que corresponde a cada letra.

Cap. 3: Análise de Resultados

Para analisar resultados partimos de um teste default, em que os seus parâmetros são os que o próprio matlab define por default para um tipo de rede patternet, sendo por isso o seu resultado bastante bom.

Os restantes testes são testes que tem o teste default por base sendo que são alterados certos parâmetros.

Os resultados destes mesmos testes estão indicados na página seguinte.

Teste Default

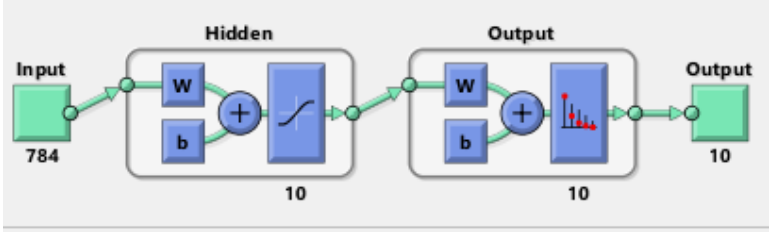

Arquitetura da rede

Coeficiente de Aprendizagem=0.01

Épocas= 1000

Função de treino : traincg

Tipo de rede: patternet

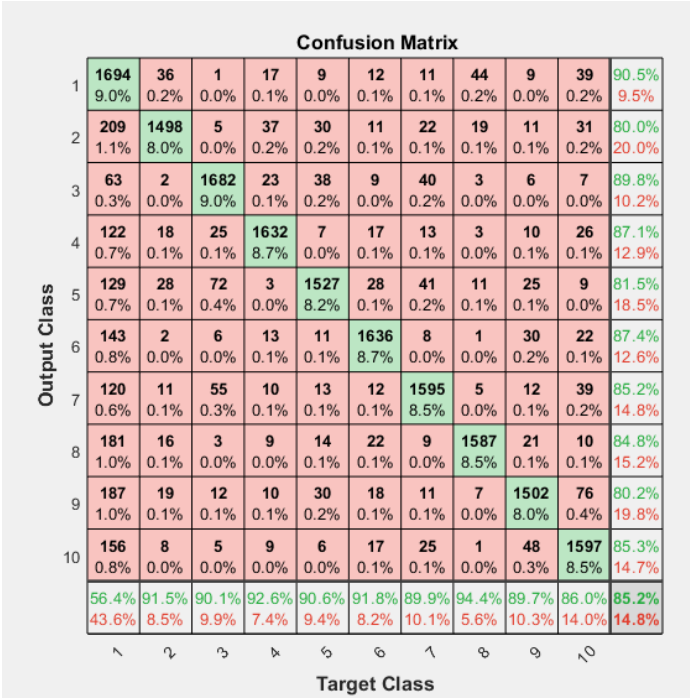

Matriz de confusão

Classes/Métricas	0	1	2	3	4	5	6	7	8	9
Precisão	0.90	0.80	0.90	0.87	0.82	0.87	0.85	0.85	0.80	0.85
Sensibilidade	0.56	0.91	0.90	0.93	0.91	0.92	0.90	0.94	0.90	0.86
F-meseaure	0.69	0.851	0.90	0.89	0.86	0.89	0.87	0.89	0.84	0.85

Teste 1- Alteração da arquitetura

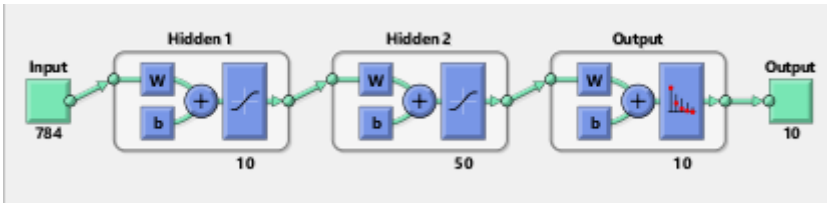

Arquitetura da rede

Coeficiente de Aprendizagem=0.01

Função de treino : traincg

Tipo de rede: patternet

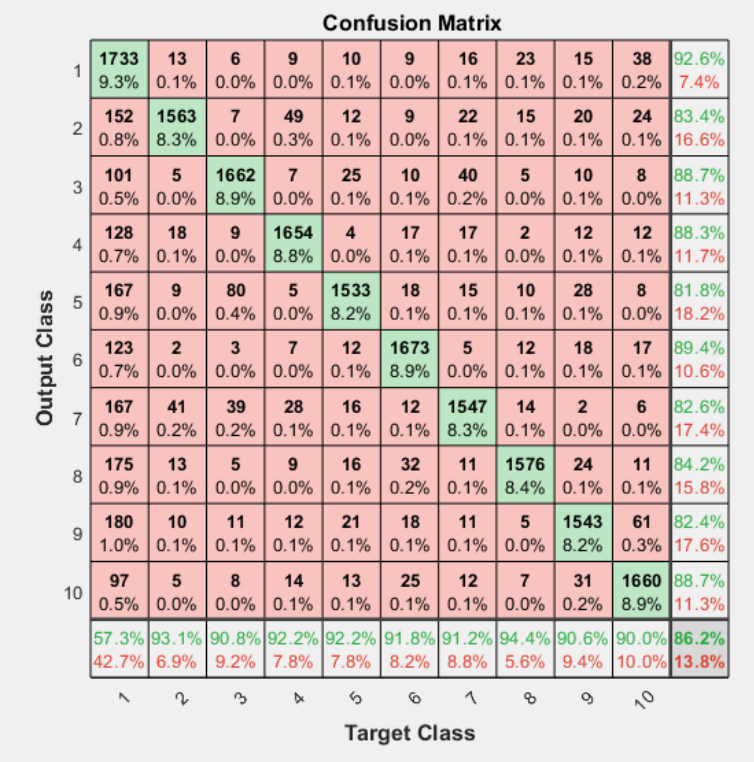

Matriz de confusão

Classes/Métricas	0	1	2	3	4	5	6	7	8	9
Precisão	0.93	0.83	0.88	0.88	0.81	0.89	0.82	0.84	0.82	0.88
Sensibilidade	0.57	0.93	0.90	0.93	0.92	0.91	0.91	0.94	0.90	0.90
F-meseaure	0.70	0.87	0.90	0.89	0.86	0.90	0.87	0.89	0.86	0.90

Teste 2- Alteração do coeficiente de aprendizagem

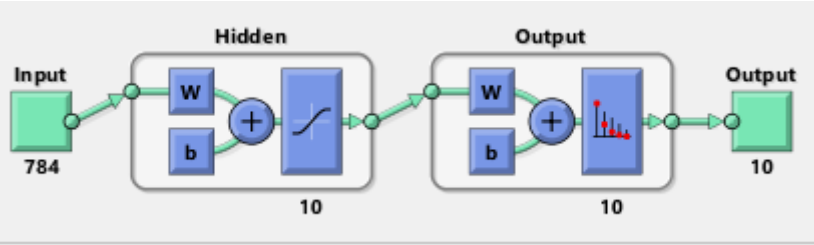

Arquitetura da rede

Coeficiente de Aprendizagem=0.1

Função de treino : traincg

Tipo de rede: patternet

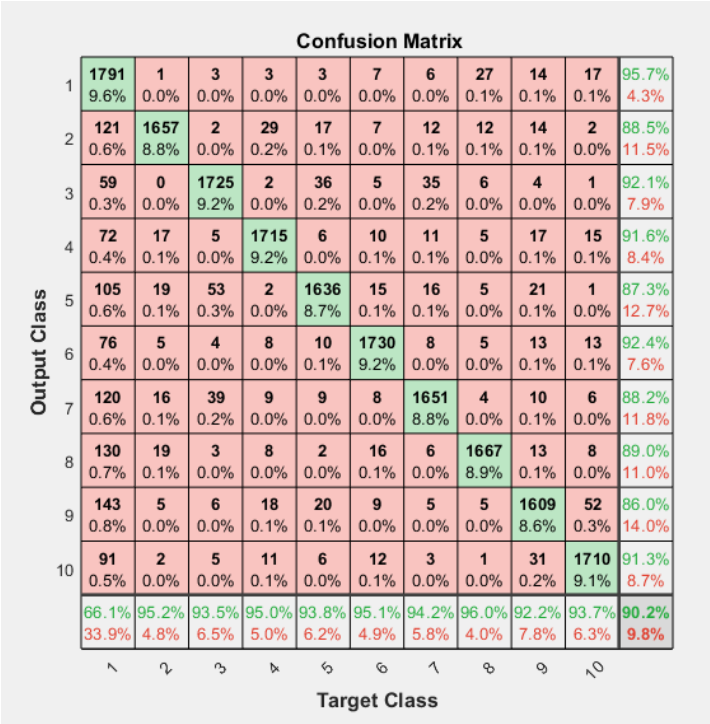

Matriz de confusão

Classes/Métricas	0	1	2	3	4	5	6	7	8	9
Precisão	0.95	0.88	0.92	0.91	0.87	0.92	0.88	0.89	0.86	0.91
Sensibilidade	0.66	0.95	0.93	0.95	0.93	0.95	0.94	0.96	0.92	0.93
F-meseaure	0.78	0.91	0.92	0.93	0.93	0.90	0.92	0.89	0.89	0.92

Teste 3-Alteração da função de treino

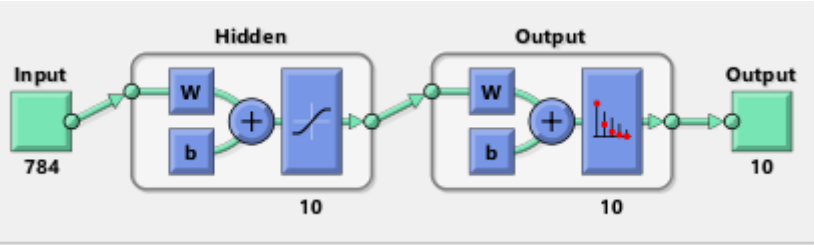

Arquitetura da rede

Coeficiente de Aprendizagem=0.01

Função de treino : traingd

Tipo de rede: patternet

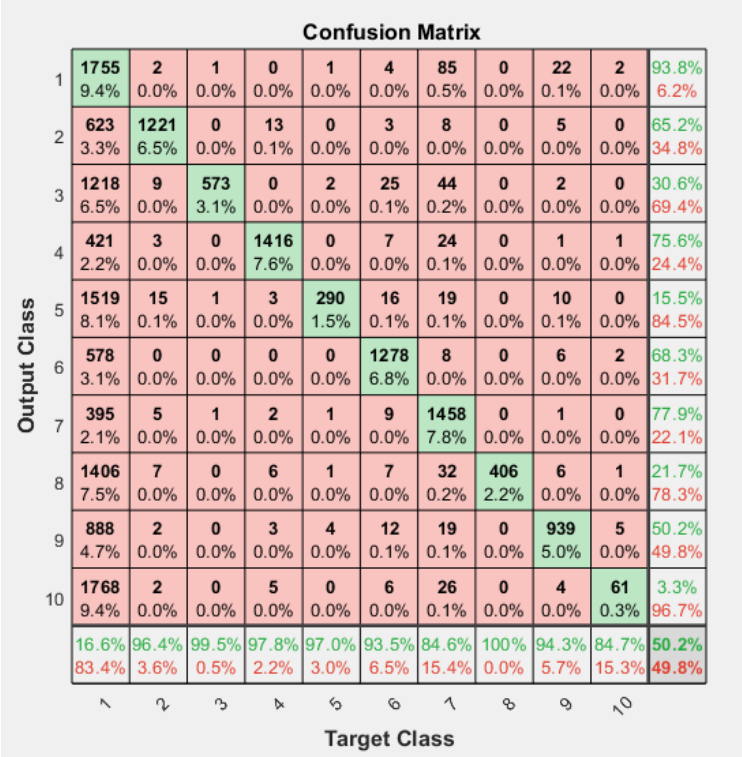

Matriz de confusão

Classes/Métricas	0	1	2	3	4	5	6	7	8	9
Precisão	0.94	0.65	0.31	0.76	0.16	0.68	0.78	0.22	0.50	0.03
Sensibilidade	0.16	0.96	0.99	0.97	0.97	0.93	0.84	1	0.94	0.84
F-meseaure	0.28	0.77	0.47	0.85	0.25	0.78	0.81	0.36	0.65	0.05

Teste 4-Alteração da função de treino com mais iterações

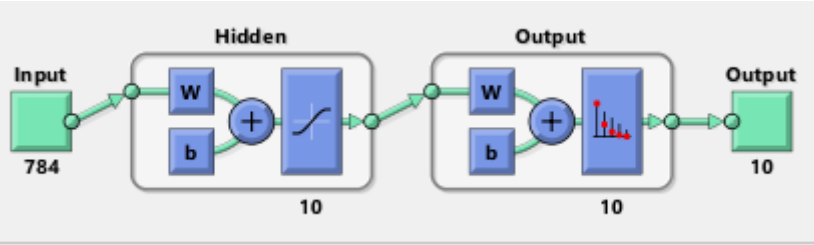

Arquitetura da rede

Épocas=10000

Coeficiente de Aprendizagem=0.01

Função de treino : traingd

Tipo de rede: patternet

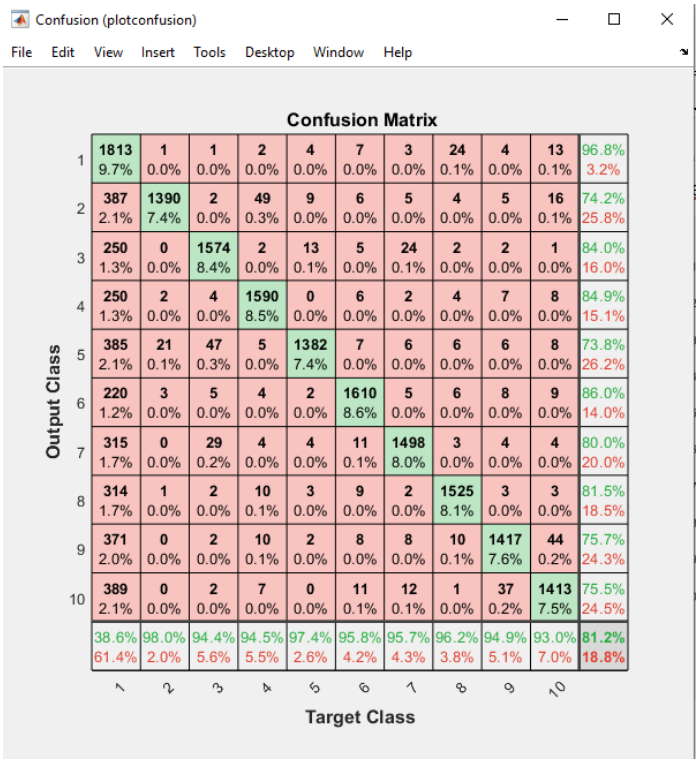

Matriz de confusão

Classes/Métricas	0	1	2	3	4	5	6	7	8	9
Precisão	0.96	0.74	0.84	0.85	0.73	0.86	0.80	0.81	0.75	0.75
Sensibilidade	0.36	0.98	0.94	0.97	0.95	0.95	0.96	0.94	0.93	0.94
F-meseaure	0.55	0.84	0.88	0.89	0.83	0.90	0.87	0.87	0.84	0.83

Cap. 4: Conclusões

Como já foi referido anteriormente o teste default serve como um "benchmark" teste para poder comparar os outros testes com este mesmo teste.

Em relação ao teste 1, foi alterada a arquitetura da rede neuronal passando agora a contar com duas hidden layers [10 50] em vez de uma [10].Através dos resultados obtidos podemos concluir que a performance da rede subiu ligeiramente, concluindo assim também que o aumentar do número de hidden layers ajuda ao aumento da performance neste caso de estudo.

Em relação ao teste 2, foi alterado o coeficiente de aprendizagem de 0.01 para 0.1. Sendo que os resultados passaram de uma média de 85 para 90.Através dos resultados obtidos podemos concluir que a performance da rede subiu significativamente, concluindo assim também que o aumentar do número do coeficiente de aprendizagem ajuda ao aumento da performance neste caso de estudo.

Em relação ao teste 3, foi alterada a função de treino de traincg para traingd. Sendo que os resultados passaram de uma média de 85 para 50. Através dos resultados obtidos podemos concluir que a performance da rede desceu muito significativamente, sendo que por isso a função traingd não é das melhores funções de treino tendo em conta este caso de uso.

Por fim em relação ao teste 3, foi alterada a função de treino de traincg para traingd e aumentado o número de épocas de 1000 para 10000. Sendo que os resultados passaram de uma média de 85 para 81. Através dos resultados obtidos podemos concluir que a função de treino traincg realmente não é mesmo das melhores funções de treino para usar neste caso de estudo pois mesmo após 10x mais épocas os resultados ainda são piores.

Referências

http://yaroslavvb.blogspot.com/2011/09/notmnist-dataset.html

https://www.kaggle.com/lubaroli/notmnist